



UNIVERSITÀ
DEGLI STUDI
DI MILANO

Integrazione dei metodi di machine learning nei DBMS

Fidanza Riccardo

Matr: **941677**

Relatore: **Prof. Alfio Ferrara**


Correlatore: **Dott.ssa Darya Shlyk**

Contesto

Opportunità offerte dalla tecnologia relazionale:

- Calcolo vicino ai dati
- Ottimizzazione della query
- Scalabilità ed efficienza della gestione dati

Aree di possibile integrazione




SQML

- Framework volto a integrare la fase di inferenza nei DBMS
- I modelli ML vengono implementati mediante le query SQL
- Esempio: Regressione Logistica in SQL


```
WITH step AS (  
    SELECT training.row AS label, test.row AS id,  
           1/(1+POW( {math.e},  
                    (training.bias+SUM(training.value*test.value)))  
           ) AS prob  
    FROM training, test  
    WHERE training.column = test.column  
    GROUP BY training.row, test.row, training.bias  
)  
SELECT label, id  
FROM step  
WHERE prob >= (  
    SELECT MAX(prob)  
    FROM step AS s  
    WHERE s.id = step.id )  
ORDER BY id
```

Framework SQML: Tecnologie



L'integrazione tra l'ambiente di sviluppo Python ed i DBMS
mediata dalla tecnica di **Object Relational Mapping**

SQLML: PIPELINE ML INTEGRATA



- I parametri del modello addestrato importati come tabelle nel database
- La fase di inferenza gestita mediante l'esecuzione di una query SQL con il DBMS

SQLML:

Implementazione e utilizzo

```
sqlml
|
|—— knn.py
|   |—— KnnClassifierC00
|   |—— KnnClassifierRE
|
|—— decision_trees.py
|   |—— DecisionTreeC00
|   |—— DecisionTreeRE
|
|—— random_forest.py
|   |—— RandomForestC00
|   |—— RandomForestRE
|
|—— logistic_regression.py
|   |—— LogisticRegressionC00
|   |—— LogisticRegressionRE
```

```
# engine per connessione al db
sqlite = 'connection_line'
engine = create_engine(sqlite)

# creazione dell'istanza del modello
from sqlml.decisionTree import DecisionTreeC00
model = DecisionTreeC00()

# addestramento del modello
model.fit(X_train, y_train, engine)

# predizione con il modello addestrato
results = model.predict(X_test)
```

Gestione dei diversi formati di dati in SQML

Id	Altezza	Peso	Genere	Età
1	1.70	70	M	45
2	1.65	60	F	22
3	1.89	80	M	34



Dati densi:
rappresentazione relazionale

Riga	Colonna	Valore
1	1	4
1	2	1
2	2	3

Dati sparsi:
Conversione nel formato COO style
per garantire l'efficienza di calcolo

Analisi delle prestazioni

Valutazione dei tempi di inferenza delle diverse implementazioni dei modelli integrati in SQML eseguita sui dati densi e sparsi.



Conclusioni

- Modelli integrati nei DBMS con successo
- Framework versatile ed efficiente

Sviluppi futuri

- Estensibilità ad altri backend
- Integrazione di nuovi algoritmi



Grazie